

Computational Intelligence in Electrical Engineering Vol. 14, No. 1, 2023 Research Paper

## Automated Brain Tumor Segmentation on Multi-MR Sequences to Determine the Most Efficient Sequence using a Deep Learning Method

Farzaneh Dehghani <sup>1</sup>, Hossein Arabi <sup>2</sup>, Alireza Karimian <sup>3\*</sup>

- <sup>1</sup> M.A., Dept. of Biomedical Engineering, Faculty of Engineering, University of Isfahan, Isfahan, Iran
- <sup>2</sup> Associate Researcher, Division of Nuclear Medicine and Molecular Imaging, Geneva University Hospital, Geneva University, Geneva, Switzerland
- <sup>3</sup> Associate Professor, Dept. of Biomedical Engineering, Faculty of Engineering, University of Isfahan, Isfahan, Iran

#### **Abstract:**

Brain tumor segmentation is an important step in the diagnosis and treatment planning of cancer patients. The procedure of manual brain tumor segmentation suffers from a long processing time. In this light, automatic brain tumor segmentation is highly appealing in the clinical routine. This study sets out to segment the tumors from brain MR images and to investigate effectiveness/usefulness of the different MRI sequences for this purpose. Here, the MR images from the BRATS challenge were utilized. 310 patients with four different MRI sequences, including T1, T1ce, T2, and FLAIR were employed to train a ResNet deep CNN. Four separate models were trained with each of the input MR sequences to identify the best sequence for brain tumor segmentation. To assess the performance of these models, 60 patients (external dataset) were quantitatively evaluated. The quantitative results indicated that the FLAIR sequence is more reliable for automatic brain tumor segmentation than other sequences with an accuracy of 0.77±0.10 in terms of Dice compared to Dice indices of 0.73±0.12, 0.73±0.15, and 0.62±0.17 obtained from T1, T2, and T1ce sequences, respectively. Based on the results of this study, FLAIR is a more reliable sequence than other sequences for brain tumor segmentation.

**Keywords**: Segmentation, MRI, Deep learning.

#### مقاله يزوهشي

# بخش بندی خودکار تومورهای مغزی در توالیهای مختلف تصاویر MRI به منظور تعیین کاراترین توالی با استفاده از روش یادگیری عمیق

فرزانه دهقانی ۱، حسین عربی ۲، علیرضا کریمیان ۳۳

۱- کارشناسی ارشد مهندسی پزشکی، دانشکده فنی و مهندسی - دانشگاه اصفهان - اصفهان - ایران Farzaneh70d@gmail.com

۲- دانشیار پژوهشی، بخش تصویربرداری پزشکی هسته ای- بیمارستان دانشگاه ژنو- دانشگاه ژنو- ژنو- ژنو-

## Hossein.Arabi@unige.ch

۳- دانشیار، گروه مهندسی پزشکی، دانشکده فنی و مهندسی - دانشگاه اصفهان - اصفهان - ایران karimian@eng.ui.ac.ir

چکیده: بخشبندی تومور مغزی گامی مهم در تشخیص بیماری و روند درمان است. بخشبندی دستی تومورهای مغزی روشی زمانبر است. هدف از این مطالعه، بخشبندی خودکار تومور مغزی تصاویر MRI و بررسی میزان دقت توالیهای مختلف MRI در بخشبندی تومور مغزی است. برای این منظور، از تصاویر موجود در پایگاه دادهٔ BRATS استفاده شده است. برای آموزش شبکه، ۳۱۰ تصویر MRI در چهار توالی T2W ، T1ce ، T1W و همچنین، تصاویر بخشبندی شدهٔ مرجع استفاده شدند. در این مرحله از شبکهٔ عصبی یادگیری عمیق ResNet استفاده شد. پس از آموزش شبکه، عملیات بخشبندی روی ۳۰ تصویر MRI آزمایش انجام شد. با توجه به نتایج بهدستآمده از پارامتر شباهت، توالی FLAIR عملکرد بهتری نسبت به سایر توالی ها به منظور بخشبندی تومور مغزی داشته است. مقدار این پارامتر برای FLAIR برابر با ۲/۱۰ ± ۷/۰ است؛ در حالی که مقدار آن برای ۲۱س برایر با ۲/۱۰ ± ۲/۰ است. همچنین، توالی مقدار آن برای ۲۱ست بیشتری برای بخشبندی تومور مغزی داشته و مقدار آن برابر با ۲/۱۰ ± ۲/۰ است. براساس نتایج این مطالعه، FLAIR توالی قابل اعتمادتری نسبت به سایر توالی ها برای بخشبندی تومور مغزی داشته و مقدار آن برابر با ۲/۱۰ ± ۱۰/۱۰ است. براساس نتایج این مطالعه، FLAIR توالی قابل اعتمادتری نسبت به سایر توالی ها برای بخشبندی تومور مغزی داشته و مقدار آن برابر با ۲/۱۰ ± ۱۰/۱۰ است. براساس نتایج این مطالعه، FLAIR توالی قابل اعتمادتری نسبت به سایر توالی ها برای بخشبندی تومور مغزی است.

واژههای کلیدی: بخش بندی تومور، MRI، شبکهٔ عصبی عمیق.

#### ۱ – م*قد*مه

تومورهای مغزی میتوانند در شکلها و اندازههای مختلفی ظاهر شوند و تا زمان تشخیص به اندازهٔ کافی رشد

کنند. متداول ترین نوع تومورهای مغزی در بزرگسالان گلیوم است که از سلولهای گلیال ایجاد شده است. براساس درجهٔ وخامت گلیوم و منشأ آن، این نوع تومور مغزی به دو نوع گلیوم درجه بالا (HGG) و گلیوم درجه پایین نوع گلیوم درجه بالا (LGG) تقسیم می شود (۱). یک روش معمول برای غربالگری تومورهای مغزی، تصویربرداری تشدید مغناطیسی (MRI) است که در آن می توان مکان تومور را تعیین کرد. درواقع اسکن MRI از مغز علاوه بر اینکه اساس غربالگری تومور است، برای برنامه ریزی قبل از عمل جراحی یا پر تودرمانی نیز استفاده می شود (۲).

ا تاریخ ارسال مقاله: ۱۳۹۹/۰۸/۳۰ تاریخ پذیرش مقاله: ۱٤٠٠/۰۹/۰۹ نام نویسندهٔ مسئول: علیرضا کریمیان نشانی نویسندهٔ مسئول: ایران – اصفهان – دانشگاه اصفهان – دانشکده فنی و مهندسی

متداول ترین روش درمان تومورهای مغزی، جراحی است. اگرچه ممكن است روش هايي نظير يرتودرماني و شیمی درمانی نیز برای کاهش سرعت رشد تومورهایی استفاده شوند که خارج کردن آنها مشکل است. بخش بندی تومورهای مغزی در تصاویر MRI می تواند تأثیر چشمگیری در تشخیص صحیح تومور و پیش بینی سرعت رشد آن و همچنین، برنامه ریزی برای درمان داشته باشد. برخی از تومورها مانند مننژیوم را می توان به راحتی بخش بندی کرد؛ در حالی که مشخص کردن محل تومورهایی مانند گلیـوم و گلیوبلاستوم بسیار دشوارتر است. این تومورها (همراه با تورم اطراف آنها) بیشتر پراکندهاند و تضاد ضعیفی بـا بافـت سالم اطراف خود دارند و به ساختارهایی شاخک مانند گسترش پیدا می کنند که بخش بندی آنها را دشوار می کند. مشکل اساسی دیگر در بخش بندی تومورهای مغزی این است که می توانند در هر نقطه از مغز، تقریباً به هر شکل و اندازهای ظاهر شوند (۳).

بخش بندی تومورهای مغزی توسط رادیولوژیستهای با تجربه همچنان بهعنوان مرجعی استاندارد در نظر گرفته می شود. با این حال، روشهای بخش بندی نیمهخودکار و تمامخودکار رایانهای، افزایش سرعت بخش بندی و تکرارپذیری نتایج را موجب می شوند. همچنین، روشهای بخش بندی تمام خودکار ناهماهنگی میان مشاهده گر و درون مشاهده گر را از بین می برد که ناشی از عواملی مانند اختلاف در تخصص و توجه و خطاهای ناشی از خستگی بینایی است. علاوه بر این، با ظهور الگوریتمهای تقسیم بندی با استفاده از شبکههای عصبی کانولوشنی، پیشرفت چشمگیری در افزایش شباهت بخش بندی در روش دستی و چومای است و موجود آمده است (۱۵۸۰).

در سال های اخیر، محققان بسیاری روش هایی برای بخش بندی خودکار و نیمه خودکار تومورهای مغزی ارائه کردهاند. با توجه به موفقیتهای اخیر الگوریتمهای شبکه عصبی کانولوشنی، مطالعات گستردهای در حوزهٔ بخش بندی خودکار تومورهای مغزی با استفاده از یادگیری عمیق انجام شده است (۹, ۱۰). در سال ۲۰۱۳، اصلیان و همکاران یک روش نیمهاتوماتیک به منظور بخش بندی تومور مغزی ارائه دادند. در این روش ابتدا ۳ انکولوژیست به صورت دستی

تومور مغزی ۱۰ بیمار را بخش بندی کردنید. سیس برای جلوگیری از سوگیری حافظه، از چهارمین انکولوژیست با تجربه خواسته شد تا با توجه به پیچیدگی شکل هدف (ادم یا تومور)، ٤ تا ٨ نقطه در اطراف هدف را روي سكانسهاي MRI انتخاب کند. در مرحله آخر، منحنی با بیشترین دقت به طور خود کار بین این نقاط درونیابی شد و بدین ترتیب منحنی اولیه برازش شد. منحنی اولیه به سرعت براساس به حداقل رساندن تابع انرژی تکامل یافت و درنهایت به مرز منطقه مدنظر، حجم هدف باليني، همگرا شد. ميانگين یارامتر شباهت در این روش، ۸۲/۰ و میانگین یارامتر هاسدورف ۱/۹۱ بوده است (۱۱). در سال ۲۰۱۳، هـوايي و همكاران يك شبكهٔ عصبي كانولوشني براي بخش بندي تومورهای مغزی تصاویر MRI موجود در پایگاه دادهٔ BRATS آموزش دادند. شبكهٔ عصبی كانولوشنی ارائه شده از یک معماری آبشاری ٔ استفاده کرده است که نتیجهٔ شبکهٔ عصبی پایه به عنوان یک منبع اطلاعاتی دیگر برای شبکهٔ عصبی بعدی استفاده میشود. مقدار یارامتر شباهت بهدست آمده در این مطالعه ۱۸/۱ است (۳). در سال ۲۰۱۳، پریرا و همکاران مطالعهٔ مشابهی روی بخش بندی تومور مغزى با استفاده از مدل شبكهٔ عصبي كانولوشني همراه با نرمالسازی شدت و افزایش دادهها بهمنظور افزایش دقت بخشبندی تومور انجام دادند. پارامتر شباهت بهترتیب برای کل تومور، هسته تومور و مناطق افزایشی تومور ۸۸/۰، ۱۸۳۰ و ۷/۷۷ به دست آمـد (۱۲). در سال ۲۰۱۷، کامینتسـاس و همكاران يك شبكهٔ عصبي كانولوشـني چنـد مقيـاس كـاملاً متصل<sup>٥</sup> را پیشنهاد كردنـد و از اولـین كسـانی بودنـد كـه از کانولوشنهای سه بعدی استفاده کردند که شامل یک مسیر با وضوح بالا و یک مسیر با وضوح پایین است که ترکیب شدهاند تا خروجی بخش بندی نهایی را تشکیل دهند (۱۳). دونگ و همکاران در سال ۲۰۱۷ مدلی مبتنی بر معماری -U Net را به منظور شناسایی و بخش بندی تومور مغزی ارائه دادند. در این مطالعه ۲۲۰ تصویر MRI از مجموعه دادههای BRATS 2015 استفاده شد. يارامتر شباهت گزارش شده در این روش ۱۸۸۰ است (۱٤). ایزنسی و همکاران در سال ۲۰۱۷ با استفاده از معماری U-Net مطالعهٔ مشابهی را به منظور بخش بندى خودكار تومور مغزى مجموعه داده

BRATS 2015 ارائه کردند. مقدار یارامتر شباهت برای کل تومور، هستهٔ تومور و مناطق افزایشی تومور بهترتیب ۰/۷۹۷، ۱۹۸۰ و ۱۳۷۸ بـ دسـت آمـد (۹). ونینگـر و همکاران در سال ۲۰۱۸ از یک مدل T-Net بعدی بهمنظور بخشبندی خودکار تومور مغزی با استفاده از مجموعه دادهٔ BRATS 2018 استفاده کردند. با توجه به نتایج به دست آمده در این مطالعه، مقدار پارامتر شباهت برای کل تومور ۱/۸۶ است (۲). چن و همکارانش در سال ۲۰۲۰ یک روش دو مرحلهای برای بخشبندی خودکار تومور مغــزى روى تصــاوير پايگــاه دادهٔ BRATS 2015 و BRATS 2018 انجام دادند. در این روش، ابتدا کل تومـور مغزی با استفاده از طبقهبندی جنگل تصادفی و ویژگی های ظاهری مشخص شد. در مرحله دوم وکسلهای موجود در ماسک بهدست آمده به انواع مختلف تومور یا بافت طبقهبندی شدند. مقدار پارامتر شباهت بهدست آمده در این مطالعه براي مجموعه دادههاي BRATS 2015 و BRATS 2018 بهترتیب ۸/۸۶ و ۱/۸۶ است (۱۵). دای و همکاران در سال ۲۰۲۰ مطالعهای به منظور ساخت تصاویر MRI تومور مغزى انجام دادند. هدف از اين مطالعه توليد توالیهای یک تصویر از یکی از توالیها بهمنظور کاهش زمان تصویربرداری از بیمار بوده است. در این مطالعه از یک unified generative adversaria شبكهٔ عصبی به نام استفاده شده است که در آن تصویری به همراه برچسب توالی آن به شبکه داده می شود و در خروجی توالی های دیگر آن تصویر تولید می شود تا زمان طولانی تصویربرداری در MRI کاهش یابد (۱٦). زینالدین و همکاران در سال ۲۰۲۰ مطالعهای به منظور بخش بندی خودکار تومور مغزی در توالی FLAIR تصاویر MRI موجود در پایگاه دادهٔ BRATS 2020 انجام دادند که در آن از شبکهٔ عصبی عميق استفاده شد. در اين مطالعه، مدل U-Net بهعنوان روش پایه یادگیری عمیق استفاده شد که در آن از ۳ مدل شبكهٔ عميق شامل DenseNet ،ResNet و NASNet استفاده شد. نتایج به دست آمده برای پارامترهای شباهت و فاصله هاسدورف بهترتیب ۸۸٬۰-۱۸/۱ و ۱۹/۷-۸/۸ است (۱۷). رینیواس و همکاران در سال ۲۰۲۰ مطالعهای بهمنظور بخش بندی تومور مغزی با استفاده از توالی های T1c ،T2 و

FLAIR انجام دادند. در این مطالعه از تصاویر موجود در پایگاد دادهٔ PRATS و از مسلال Pu-Net بسرای BRATS و یایگاه دادهٔ 2018 و از مسلال Pu-Net بستخراج ویژگی استفاده شد. در این مطالعه، ابتدا در تصاویر T2 و FLAIR کل ناحیهٔ تومور تشخیص داده شد. سپس این تصاویر بهمنظور یادگیری ناحیهٔ هسته و ناحیهٔ درحال افزایش تومور در تصاویر T1c استفاده شدند. نتیجهٔ بهدست آمده برای پارامتر شباهت ۱۹۲۰ است (۱۸).

هدف از این تحقیق، بخش بندی خودکار تومورهای مغزى تصاوير MRI با استفاده از شبكهٔ عصبى قدرتمند ResNet و بررسی میزان دقت توالیهای مختلف MRI در بخش بندی تومور مغزی و معرفی کاراترین توالی بـهمنظـور کاهش زمان تصویربرداری است (۱۹-۲۱). شبکههای عصبي كانولوشني يكي از بهترين ساختارهاي عصبي توسعه یافته بر پایهٔ شبکه های عصبی تصویر محور است (۲۲-۲۲). مشخص كردن توالى از MRI با بهترين عملكرد در بخشبندی تومور مغزی (توالی که در آن تومور با بیشترین میزان دقت تشخیص داده می شود) می تواند مدت زمان تصویربرداری را کاهش دهد که این امر، راحتی بیمار و کاهش هزینه تصویربرداری را به همراه می آورد. برای این منظور، تصاویر موجود در پایگاه دادهٔ MICCAI brain tumor segmentaion (BRATS) بررسی شدند. مراحل انجام این مطالعه شامل پیشپردازش تصاویر (استخراج ناحیهٔ مدنظر (ROI) و بهنجارکردن آنها)، آموزش شبکه و سپس بخشبندی تصاویر آزمایش با استفاده از بستر ResNet و شبكهٔ عصبی اختصاصی NiftyNet درنهایت ارزیابی نتایج به دست آمده است.

## ٢- مطالب اصلى

## ۱-۲ دادههای MRI بیماران

در ایس مطالعه از تصاویر موجود در پایگاه دادهٔ BRATS به منظور آموزش و ارزیابی شبکهٔ عصبی کانولوشنی برای بخش بندی تومور مغزی استفاده شده است. این پایگاه داده شامل ۳۷۰ تصویر MRI بیمارانی با گلیوم درجه بالا و گلیوم درجه پایین در چهار توالی تصویربرداری با وزن T1 با کنتراست با وزن T1 با کنتراست

تقویت کنندهٔ گادولینیوم (T1ce)، تصویربرداری با وزن T2W) را FLAIR است. تمام تصاویر توسط ۱ تا ٤ رادیولوژیست با تجربه، به چهار قسمت شامل بافت مغز، بافیت مصرده (necrotic) و تومور غیرافزایشی (enhancing tumor)، ورم اطراف تومور (enhancing tumor) و تومور درحال گسترش (enhancing tumor) بخش بندی شده است. تصاویر بخش بندی شدهٔ موجود در این پایگاه داده به عنوان مرجع اصلی برای آموزش و همچنین ارزیابی تصاویر بخش بندی شده توسط الگوریتم ارائه شده استفاده شده اند.

## ۲-۲ پیش پر دازش

این مرحله شامل استخراج ناحیهٔ مدنظر و همچنین بهنجار کردن تصاویر است. به منظور استخراج ناحیهٔ مدنظر که همان ناحیهٔ تومور است، تصاویر بخش بندی شدهٔ تومور تمام بیماران در نرم افزار متلب فراخوانده شدند. سپس از میان تمام تصاویر بخش بندی شدهٔ بیماران، بزرگ ترین اندازهٔ تومور در سه جهت X، Y و Z مشخص شدند. هدف از این تومور در سه جهت کار مشخص کردن کوچک ترین اندازهٔ یکسان برای انتخاب ناحیهٔ شامل تومور در تمام تصاویر است. با توجه به اینکه نرم افزار NiftyNet تصاویری با ابعاد مضرب ۸ را به عنوان ورودی می پذیرد، کوچک ترین اندازهٔ ناحیهٔ شامل تومور برای تمام تصاویر مقدار ۱۲۸×۱۲۸ پیکسل برابر با

در مرحلهٔ بعد، با توجه به ابعاد مشخص شده برای ناحیهٔ مدنظر، تمام تصاویر در توالی های مختلف شامل T1W، T1ce و T2W و FLAIR و همچنین تصاویر بخش بندی شده، به مرکزیت تومور بریده شدند. تصاویر بخش بندی شده به تصاویر دودویی شامل ناحیهٔ تومور و ناحیهٔ غیر تومور تبدیل شدند. همچنین تصاویر MRI در چهار توالی با تقسیم شدن بر بیشترین مقدار پیکسل هر تصویر به طور جداگانه (روش z-score) به تصاویر بهنجار تبدیل شدند (شکل (۱)).

## ۲-۳- آموزش شبکهٔ عصبی

به منظ ور آموزش شبکهٔ عصبی کانولوشنی برای بخش بندی تومور مغزی، از نرمافزار NiftyNet استفاده شده است. این نرمافزار یک شبکهٔ عصبی کانولوشن منبع – باز مبتنی بر تنسورفلو ۹ است که به منظ ور انجام مطالعات در زمینهٔ تجزیه و تحلیل تصاویر پزشکی و درمان با کمک تصاویر کلینیکی استفاده می شود.

در این مطالعه، بهمنظور آموزش شبکه، ۳۱۰ تصویر MRI با ابعاد ۹۲×۱۲۸×۱۴٤ به عنوان ورودی در نظر گرفتـه شد. در مرحلهٔ آموزش شبکه از معماری شبکه HighRes3DNet استفاده شده است. شبکهٔ ResNet از ۲۰ لایهٔ کانولوشنی تشکیل شده است که در هفت لایـهٔ اول آن از هستهٔ کانولوشن ۱۰ با ابعاد ۳×۳×۳ وکسل استفاده می شود. این لایه ها ویژگی های سطح پایین مثل لبه ها را از دادهٔ ورودي استخراج ميكنند. هفت لايهٔ بعدي هستهٔ كانولوشني متسع ۱۱ را با ضریب دو برای رمزگذاری ویژگی های سطح متوسط از ورودی به کار می گیرند. شش لایهٔ آخر علاوه بـر لایههای قبلی، هستهٔ کانولوشنی متسع را با ضریب ٤ استفاده مى كنند تا امكان استخراج ويژگى هاى سطح بالا فراهم شود. یک اتصال باقی مانده ۱۲ هر دو لایهٔ کانولوشن را به هم پیوند میدهد. یک نرمالسازی دستهای ۱۳ و تابع یکسوساز خطی ۱۲ بـ لایـههای کانولوشنی واقع در بلـوکهای باقى مانده ١٥ متصل مى شود (شكل ٢) (٢٦).

در ایس مطالعه، تنظیمات شبکهٔ عصبی در ایس مطالعه، تنظیمات شبکهٔ عصبی ۱٬۹ Adam به صورت زیر انجام شد: بهینه ساز Madam و تعداد و Dice\_NS و تعداد و تعداد و تعداد تکرار ۱۰۰۰۰. در این مطالعه، هریک از تصاویر به طور جداگانه آموزش داده و بهینه سازی شدند تا بهترین تصویر برای جداسازی تومور مغزی از تصاویر MRI مشخص شود.

همچنین برای ارزیابی شبکهٔ آموزشدیده برای بخش بندی تومور مغزی، ۲۰ تصویر MRI دیگر از پایگاه دادهٔ BRATS استفاده شدند. در این مرحله، ابتدا تصاویر در نرمافزار NiftyNet، بخش بندی و سپس برای ارزیابی میزان موفقیت شبکه، در نرمافزار متلب فراخوانده شدند.

#### ۲-۶- ارزیابی

به منظور ارزیابی عملکرد الگوریتم ارائه شده برای بخش بندی تومور مغزی، پارامترهای زیر محاسبه شدهاند (۲۷).

حساسیت 
$$(S,M) = \frac{|S \cap M|}{|M|}$$
 (۱)

دقت 
$$(S, M) = \frac{|S \cap M|}{|S|}$$
 (۲)

$$= \frac{2 \times |S \cap M|}{|S| + |M|}$$
 (٣)

الا مارد 
$$= \frac{|S \cap M|}{|S \cup M|}$$
 شاخص جاکارد

(S, M) فاصله هاسدورف

$$= \max(h(A, M), h(M, S))$$

$$h(S, M) = \max_{S \in S} \min_{m \in M} ||S - m||$$
(\$\delta\$)

که در آنها، S ناحیهٔ بخش بندی شدهٔ الگوریتم پیشنهادی و M ناحیهٔ بخش بندی شدهٔ دستی یا مرجع است. پارامتر حساسیت ۱۰ نسبتی از ناحیهٔ شامل تومور به کل ناحیهٔ تومور مرجع است که مدل به درستی تشخیص داده است. پارامتر دقت ۱۸ نسبتی از ناحیه ای است که مدل به درستی به عنوان تومور تشخیص داده است، به کل ناحیهٔ تومور تشخیص داده شده توسط مدل. پارامترهای شباهت ۱۹ و شاخص جاکارد ۲۰ بهمنظور بررسی میزان شباهت یا تفاوت ناحیهٔ بخش بندی شدهٔ مرجع و مدل ارائه شده در این مطالعه اند. پارامتر فاصله هاسدورف ۱۱ نیز به منظور اندازه گیری فاصلهٔ پارامتر فاصله هاسدورف مرجع و مدل ارائه شده است.

# ۳- نتیجه گیری

## ٣-١- نتايج

در این مطالعه نتایج حاصل از بخش بندی تومور مغزی تصاویر MRI موجود در پایگاه دادهٔ BRATS بررسی شدند. در شکل (۳) دو نمونه از تصاویر MRI بیماران و نتایج بخش بندی آنها با استفاده از الگوریتم شبکهٔ عصبی ارائه شده در این مطالعه نشان داده شده اند.

به منظور ارزیابی نتایج حاصل از بخش بندی تومور مغزی تصاویر MRI توسط الگوریتم ارائه شده در این مطالعه، بررسی های کمی با استفاده از روابط ۱ تا ۵ انجام شده اند. نتایج این بررسی ها در جدول (۱) نشان داده شده اند.

به منظور بررسی دقیق تر عملکرد الگوریتم ارائه شده برای بخش بندی تومور مغزی، پارامترهای شباهت و فاصله هاسدورف برای تمام بیمارانی نشان داده شدند که تصاویر آنها آزمایش شده اند (شکلهای ٤ و ۵).

#### ٣-٢- بحث

تصویربرداری MRI روشی زمانبر بوده و برای بیماران ممکن است طاقت فرسا باشد. با توجه به آنچه در پیشینهٔ این تحقیق ارائه شد، در سالهای اخیر مطالعات گوناگونی در حوزهٔ بخش بندی تومور مغزی انجام گرفته اند؛ اما تاکنون مطالعهای به منظور بررسی میزان موفقیت توالی های مختلف در تشخیص تومور انجام نگرفته است و این نوآوری این تحقیق است.

هدف از این مطالعه، مشخص کردن توالی از MRI است که بتوان تومور مغزی را با دقت بالا تشخیص داد. درواقع مشخص کردن بهترین توالی MRI علاوه بر اینکه به ما کمک می کند در مدت زمان کمتری تومور مغزی با بیشترین میزان دقت تشخیص داده شود، بیمار مدت زمان کمتری را داخل دستگاه سپری می کند که موجب آسایش بیشتر بیمار می شود. برای رسیدن به هدف فوق، در این بیشتر بیمار می شود. برای رسیدن به هدف فوق، در این بایگاه دادهٔ BRATS با استفاده از شبکهٔ عصبی MRI موجود در پایگاه دادهٔ میزان دقت توالی های مختلف MRI به منظور یافتن کاراترین توالی انجام گرفت. برای این منظور، ابتدا پیش پردازشی روی تصاویر این پایگاه داده در نرمافزار متلب پیش پردازشی روی تصاویر این پایگاه داده در نرمافزار متلب تومور مغزی و همچنین بهنجار کردن تصاویر MRI بوده است. مدت زمان اجرای این قسمت در نرمافزار متلب

۲۰۱۹، حدود ۸ ثانیه است. در ادامه، آموزش شبکهٔ عصبی کانولوشنی در نرمافزار NiftyNet روی ۳۱۰ تصویر این یایگاه داده انجام گرفت. یس از آن، تصاویر آزمایش به تعداد ٦٠ عدد به عنوان ورودي به شبكهٔ عصبي كانولوشني طراحی شده در این تحقیق، وارد و در خروجی تصاویر بخش بندی شده دریافت شدند. مدت زمان آموزش هر تصویر در نرمافزار ۱۱/۳ NiftyNet ثانیه و مدت زمان بخش بندی هر تصویر ۱/۲ ثانیه است (مشخصات سیستم استفاده شده به این صورت است: GPU: Nvidia .(CPU: Core i9-7900X , GeForce GTX 1070 Ti به منظور بررسی عملکرد الگوریتم ارائه شده در این مطالعه، تصاویر بخش بندی شده به نرمافزار متلب، وارد و با تصاویر بخش بندی شدهٔ موجود در پایگاه داده مقایسه شدند. همچنین میزان دقت توالی های مختلف MRI شامل تصویر بر داری با وزن T1، تصویر بر داری با وزن T1 با كنتراست تقويت كنندهٔ گادولينيوم، تصوير بر داري با وزن T2 و FLAIR برای بخش بندی تومور مغزی بررسی شد. تصاویر پردازششده در صورت درخواست بهصورت آماده (پیش پردازششده) در اختیار دیگر محققان نیز قرار خواهند گرفت.

همان طور که در جدول (۱) نشان داده شده است، نتایج بخش بندی تومور در توالی FLAIR بهتر از نتیجه بخش بندی تصویر در توالیهای T1w بخش بندی تصویر در توالیهای FLAIR بهتر از نتیجه است. با توجه به این جدول، حساسیت FLAIR در بخش بندی تومور مغزی نسبت به سایر توالیها بیشتر است. توالیهای T1w و T2w نیز به تر تیب در جایگاه دوم و سوم از نظر حساسیت قرار گرفتهاند. با بررسی پارامتر شباهت (Dice) مشخص می شود تومورهای بخش بندی شده در توالی FLAIR بیشترین میزان شباهت را با تصاویر بخش بندی شده از پارامتر شباهت برای سکانسهای T1w و T2w تقریباً مشابهاند و این دو توالی در جایگاه دوم از نظر میزان شباهت با تصاویر بخش بندی شده در مرجع قرار

می گیرند. همان طور که در جدول (۱) مشاهده می شود، هر چهار توالی تقریباً عملکرد مشابهی دربارهٔ ارزیابی الگوریتم با استفاده از پارامتر فاصله هاسدورف نشان داده اند؛ هر چند T2W و T1ce به ترتیب به ترین و بد ترین عملکرد را داشته اند.

جدول (۱): نتایج حاصل از بررسی عملکرد شبکهٔ عصبی ارائهشده:

توالی ارزیابی	FLAIR	T1	T2	T1ce
Sensitivity	± •/17	± •/1٦	± •/\A	± •/٢•
(Mean ± SD)	• /٨٣	•/٧٩	•/٧٣	•/7
Precision	± •/1٤	± •/17	± •/١٦	± •/\\
(Mean ± SD)	•/٧٤	•/٦٩	•/٧٧	•/٦•
Dice	± •/1•	± •/17	± •/١٥	± •/\V
(Mean ± SD)	• /٧٧	٠/٧٣	•/٧٣	•/77
Jaccard	± •/17	± •/1٤	± •/١٦	± •/\o
(Mean ± SD)	•/٦٤	•/09	•/٦•	•/٤٦
Hausdorff Distance	± •/٦٤	± •/0•	± •/0•	± •/٥٦
(Mean ± SD)	٣/٦٥	٣/٥٩	٣/٤٨	٣/٩٨

با بررسی دقیق تر نتیجهٔ محاسبهٔ هر پارامتر روی تک تک تصاویر بیماران، مشخص شد تعدادی از این تصاویر بهدلیل نوفه بالا یا مشخص نبودن تومور بهصورت واضح، عملکرد ضعیفی در تشخیص محل تومور داشته اند؛ برای مثال، در شکل (٦) که نشان دهندهٔ تصویر MRI بیمار نمونه است، محل تومور در سه توالی T1W بیمار نمونه است، است. همین امر موجب افت شدید عملکرد الگوریتم ارائه شده روی تصاویری از این مجموعه شده است.

با توجه به اینکه تاکنون مطالعهای برای مشخص کردن کاراترین توالی در تشخیص تومور مغزی انجام نشده است، مقایسه با سایر مطالعات صرفاً به مقایسهٔ مقدار عددی پارامتر شباهت و آن هم برای داشتن حسی در خصوص محدودهٔ عددی این پارامتر، محدود شده است. در مطالعهٔ اصلیان و همکاران اگرچه مقدار میانگین یارامتر شباهت،

۰/۸۲ و میانگین پارامتر هاسدورف ۱/۹۱ بوده است، روش ارائه شده بسیار زمان بر است و به طور میانگین حدود ۳/۲۵ دقیقه برای بخش بندی هر تصویر زمان لازم است (۱۱)؛ در حالی که در این مطالعه بخش بندی هر تصویر کمتر از ۳۰ ثانیه به طول می انجامد. در مطالعات دونگ، ایزنسی و ونینگر (۱۳، ۹، ۱) از شبکهٔ عصبی U-Net استفاده شده است که نتایج پارامتر شباهت در این مطالعات بهترتیب برابر با ۰/۸٦، ۸۹/۰ و ۸۶/۰ است. گفتنی است در این مطالعات چهار توالي MRI به طور همزمان به شبكهٔ عصبي وارد شدهاند و همین امر سبب افزایش مقدار یارامتر شباهت شده است. براساس نتایج ارائهشده در جدول (۱)، بیشترین مقدار به دست آمده برای پارامتر شباهت، ۷۷/ و مربوط به توالی FLAIR است. در مطالعة زين الدين (١٧)، فقط توالي FLAIR آموزش داده شده است و سایر توالی ها به طور جداگانه بررسی نشدهاند. به طور کلی هدف این مطالعه بهینه سازی نتایج بخش بندی تومور در این توالی خاص بوده است. در مطالعهٔ رینیواس و همکاران، هدف بهینهسازی یک روش یادگیری عمیق برای بخش بندی تومور بوده است که در آن دو توالی FLAIR و T2 به منظور بخش بندی کل ناحیهٔ تومور استفاده شدند و سپس نتیجهٔ این قسمت به همراه توالی T1c برای بخش بندی هستهٔ تومور و ناحیهٔ درحال افزایش تومور استفاده شد و نتایج خوبی از این روش به دست آمد؛ گرچه ترکیب توالی ها در عملکرد روش ارائه شده تأثیر زیادی داشته است (۱۸). به طور کلی هدف مطالعات ذكرشده در بخش پیشینهٔ بهینه سازی یک روش به منظور بخش بندی تومور مغزی بوده است؛ در حالی که هدف این تحقیق مشخص کردن توالی MRI با بهترین عملکرد و بیشترین اطلاعات برای جداسازی بافت تومور و تشخیص تومور مغزی، بهمنظور کاهش زمان تصویربرداری است که این مطلب مهمترین نـوآوری ایـن تحقیـق اسـت. تصویربرداری همزمان از بیمار برای چندین توالی MRI زمانبر بوده و همچنین بهدلیل حرکت بیمار این تصاویر ممكن است بر هم منطبق نباشند. اين عدم انطباق سبب

مى شود استفادهٔ همزمان از اين تصاوير امكان پذير نباشد. الگوريتمهاي انطباق تصوير نيز بدون خطا نيستند؛ بنابراين، اگر فقط یک توالی MRI از بیمار گرفته شود و این توالی حداکثر اطلاعات مربوط به تومور را در اختیار قرار دهد، علاوه بر اینکه سبب کاهش زمان تصویربرداری می شود (که راحتی بیمار و کاهش هزینه را نیز به دنبال خواهد داشت)، از خطاهای ناشی از حرکت بیمار و عدم انطباق تصاویر نیـز جلوگیری می کند. همچنین، در این مطالعه از شبکه HighRes3DNet استفاده شده است که از لایههای با قدرت تفکیک مکانی (تفکیکینیری مکانی) بالا برای استخراج اطلاعات از تصاوير MRI استفاده مي كند. معمولاً در شبکه های عصبی به منظور کاهش تعداد متغیرهای آموزش و کمکردن بار پردازش شبکه، از لایههای کاهش تفکیک پذیری مکانی استفاده می شود که سبب از دست رفتن اطلاعات مهمی از تصاویر میشود. این موضوع اهمیت ویــژهای در یــردازش تــوالی هـای MRI دارد؛ زیــرا بــا تفکیکپذیری مکانی بالای این تصاویر، استفاده از شبکههای متداول سبب از دست رفتن قسمتی از اطلاعات موجود در این تصاویر می شود. به همین دلیل در این مطالعه، شبکهٔ HighRes3DNet پیشنهاد شده است که می تواند تصاویر MRI را بدون کاهش تفکیکپذیری مکانی و با همان دقت و جزئیات اصلی پردازش کند. روشهای دیگر مانند جداسازی به کمک اطلس یا کانتور فعال برای تومورهایی کاربر د چندانی ندارند که شکل و ابعاد کاملاً تصادفی دارند و تقریباً از هیچ نظامی پیروی نمیکنند. این روشها بیشـتر برای ارگانهایی با شکل و ابعاد قابل پیش بینی و مدل پذیر کاربرد دارند. همچنین، این روشها در بسیاری از موارد به دخالت کاربر نیاز دارند و قادر به جداسازی تومور بـهطـور كاملاً خو دكار نيستند.

مطالعهٔ انجام شده از لحاظ پزشکی نیز ارزش و اهمیت بسیاری دارد. بهطور کلی در حوزهٔ پزشکی مطالعات تخصصی بهمنظور مشخص کردن بهترین و کاراترین مدیا روش تصویربرداری، بهترین روش بخشبندی یا بهترین

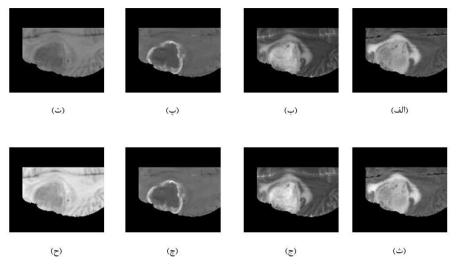
حالت ترکیب اطلاعات از روشها یا متخصصان مختلف انجام می شود؛ برای مشال، در مطالعه ای که به منظور طبقه بندی آسیب شناسی دیجیتال سرطان پروستات انجام گرفته است، تصاویر بخش بندی شده با روش هوش مصنوعی و توسط 7 متخصص با سابقه و تجربهٔ متفاوت طبقه بندی شدند. هدف این مطالعه مشخص کردن بهترین تشخیص از میان تشخیصهای این 7 متخصص بوده است (۲۸). نتایج به دست آمده از این مطالعه و مطالعاتی مشابه می توانند از نظر کلینیکی اطلاعات بسیار مفید و ارزشمندی را در اختیار محققان قرار دهند.

مشخص کردن توالی با بهترین عملکرد در تشخیص تومور مغزی، سبب میشود در کوتاهترین مدت تصویربرداری اطلاعات مورد نیاز برای تشخیص و جداسازی تومور به دست آید. در سالهای اخیر مطالعات فراوانی بهمنظور سنتز تصاویر پزشکی انجام شدهانـد کـه هدف آنها مدلسازی نقشهبرداری از تصاویر منبع به تصاویر هدف است؛ برای مثال، در مطالعهٔ دای بیان شده است که توالی های مختلف MRI قابلیت های مختلفی در تشخیص تومور مغزی دارند و بهرهبردن از نقاط قوت هرکدام از توالی ها به تشخیص بهتر تومور مغزی کمک میکند؛ اما در تصويربرداري MRI، بهدليل محدودبودن زمان تصویربرداری، تنظیمات نادرست دستگاه، وجود مصنوعات و آلرژی بیمار به مواد حاجب، اعمال چندین توالی تصویربرداری برای هر بیمار دشوار است (۱۹). این موضوع بر هدف اصلی این مطالعه صحه می گذارد که کاهش زمان تصویربرداری و استفاده از یک توالی به منظور بخش بندی تومور مغزی بوده است. با توجه به اینکه آموزش یک شبکه به طور اختصاصی برای یک کاربرد خاص، یک دستگاه خاص یا یک پروتکل تصویربرداری خاص بهینهسازی شده

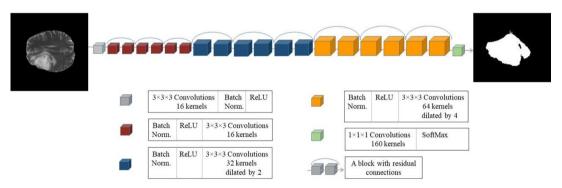
است و منجر به نتایج دقیق تری نسبت به مدلهای کلی تر می شود، ترجیح محققان این است که تا حد امکان شبکهها اختصاصی توسعه یابند (۲۱, ۲۱). در این مطالعه نیز شبکهٔ پیشنهادی روی یک تعداد توالی MRI خاص (۳۱۰ تصویر برای آموزش و ۲۰ تصویر برای آزمایش) اعمال شده است که همگی از یک دستگاه با یک پروتکل و کیفیت ثابت به دست آمدهاند؛ بنابراین، یافتههای این تحقیق بهطور اختصاصی مربوط به این مطالعه و دادهها است و نتیجه گیری کلی و بسط این یافتهها به دیگر دستگاهها و الگوریتمها بدون انجام مطالعهٔ اختصاصی امکانپذیر نیست.

## ۳-۳- نتیجه گیری

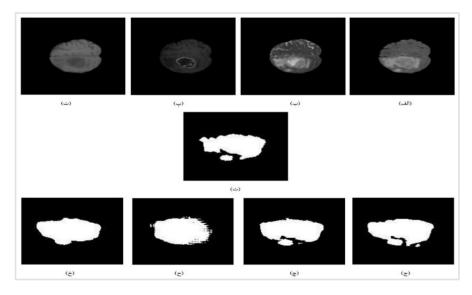
هدف از این مطالعه بخشبندی تومور مغزی تصاویر MRI با استفاده از شبكهٔ عصبی ResNet و بررسی میزان موفقیت توالی های مختلف تصاویر MRI برای این منظور است. مشخص کردن توالی با بهترین عملکرد در تشخیص تومور مغزی، سبب می شود ضمن تشخیص تومور مغزی با بیشترین میزان دقت، زمان کمتری برای تصویربرداری از بیمار صرف شود که افزایش سرعت تصویربرداری و امکان انجام تصویربرداری از تعداد بیشتری بیمار و درنهایت کاهش هزینههای تصویربرداری را موجب می شود. با توجه به نتایج به دست آمده، شبکهٔ عصبی معرفی شده عملکرد مناسبی برای بخشبندی تومور مغزی دارد. براساس این مطالعه، توالی FLAIR حساسیت بیشتری در بخش بندی تومور مغزی داشته است. همچنین مقدار یارامتر شباهت برای توالی FLAIR نسبت به سایر توالی ها بیشتر بوده است. همچنین نتایج این تحقیق نشان دادند میران عملکرد توالى هاى T1W و T2W تقريباً يكسان است و در رتبه بعد از توالى FLAIR قرار دارند.



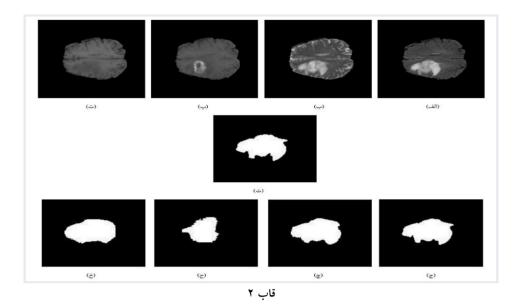
MRI شکل (۱): نمونه تصاویر MRI یک بیمار موجود در پایگاه داده در ٤ توالی. تصاویر (الف)، (ب)، (پ) و (ت) به تر تیب تصاویر MRI پایگاه داده در ٤ توالی T1ce، T2W ،FLAIR و T1W هستند. تصاویر تصویر (ث)، (ج)، (ج)، (ج) به تر تیب نتایج بهنجارسازی تصاویر MRI در ٤ توالی T1ce، T2W ،FLAIR و T1W است. تصاویر تومور با بزرگنمایی دو برابر نسبت به تصاویر MRI نمایش داده شده اند.



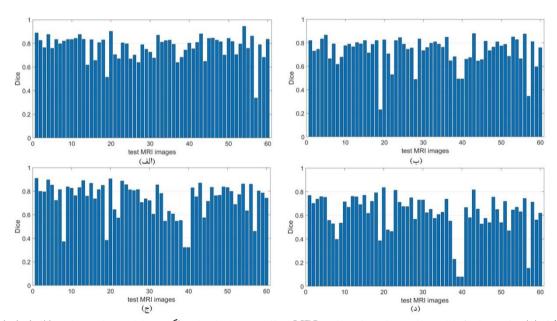
شكل (٢): شماى كلى شبكة عصبي كانولوشني ReLU



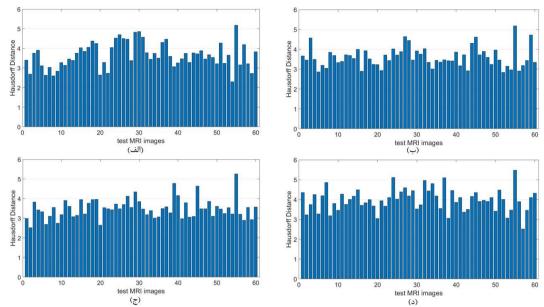
قاب ١

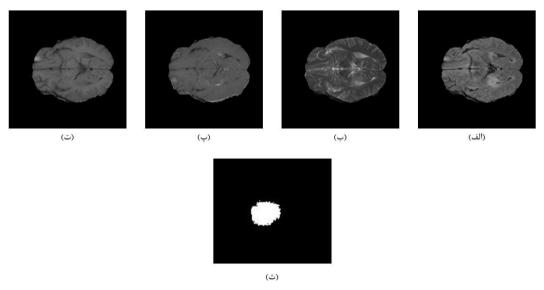


شکل (۳): نمونه تصاویر MRI دو بیمار موجود در پایگاه داده در ٤ توالی. در هر تصویر (قاب ۱ و ۲) بیمار نمونه، تصاویر (الف)، (ب)، (پ) و (ت) به ترتیب تصاویر MRI پایگاه داده در ٤ توالی Tice ،T2W ،FLAIR و T1W هستند. تصویر (ث) تصویر بخش بندی شده توسط متخصصان در پایگاه داده است. تصاویر (ج)، (ج)، (ح) و (خ) به ترتیب نتایج بخش بندی تصاویر MRI توسط الگوریتم یادگیری عمیق ارائه شده در ٤ توالی T1ce ،T2W ،FLAIR و T1W است. تصاویر تومور با بزرگنمایی دو برابر نسبت به تصاویر MRI نمایش داده شده اند.



شکل (٤): نتایج محاسبهٔ پارامتر شباهت برای تمام تصاویر MRI استفاده شده برای ارزیابی الگوریتم ارائه شده اند. تصاویر (الف)، (ب)، (ج) و (د) به ترتیب نتایج پارامتر شباهت برای تصاویر MRI در ٤ توالی T1w ،FLAIR و T1ce هستند.





شکل (۲): نمونهای از تصویر MRI یکی از بیماران در ٤ توالی که نتیجه بخشبندی ضعیفی داشته است. تصاویر (الف)، (ب)، (پ) و (ت) بهترتیب تصاویر MRI بیمار در ٤ توالی FLAIR، FLAIR و T1W هستند. تصویر (ث) نیز تصویر بخشبندی شدهٔ مرجع است. مقدار پارامتر شباهت برای این بیمار در توالیهای T1ce، T2W، FLAIR و T1W بهترتیب ۲/۲۹، ۲/۲۵، ۰/۲۵ و ۰/۲۶ است.

- tumor segmentation and radiomics survival prediction: Contribution to the brats 2017 challenge. *International MICCAI Brainlesion Workshop*; 2017: Springer.
- [10] Arabi H, Zaidi H. Applications of artificial intelligence and deep learning in molecular imaging and radiotherapy. *European Journal* of *Hybrid Imaging*. Vol. 4, No.1, pp. 1-23, 2020.
- [11] Aslian H, Sadeghi M, Mahdavi SR, Mofrad FB, Astarakee M, Khaledi N, et al. Magnetic resonance imaging-based target volume delineation in radiation therapy treatment planning for brain tumors using localized region-based active contour. *International Journal of Radiation Oncology\* Biology\* Physics.* Vol. 87, No. 1, pp. 195-201, 2013.
- [12] Pereira S, Pinto A, Alves V, Silva CA. Brain tumor segmentation using convolutional neural networks in MRI images. *IEEE transactions on medical imaging*. Vol. 35, No. 5, pp. 1240-51, 2016.
- [13] Kamnitsas K, Ledig C, Newcombe VF, Simpson JP, Kane AD, Menon DK, et al. Efficient multi-scale 3D CNN with fully connected CRF for accurate brain lesion segmentation. *Medical image analysis*. Vol. 36, pp. 61-78, 2017.
- [14] Dong H, Yang G, Liu F, Mo Y, Guo Y, editors. Automatic brain tumor detection and segmentation using U-Net based fully convolutional networks. annual conference on medical image understanding and analysis; 2017, Springer.
- [15] Chen G, Li Q, Shi F, Rekik I, Pan Z. RFDCR: Automated brain lesion segmentation using cascaded random forests with dense conditional random fields. *NeuroImage*. Vol. 211, p. 116620, 2020.
- [16] Dai X, Lei Y, Fu Y, Curran WJ, Liu T, Mao H, et al. Multimodal MRI synthesis using unified generative adversarial networks. *Medical physics*. Vol. 47, No. 12, pp. 6343-54, 2020.
- [17] Zeineldin RA, Karar ME, Coburger J, Wirtz CR, Burgert O. DeepSeg: deep neural network framework for automatic brain tumor segmentation using magnetic resonance FLAIR images. *International journal of computer assisted radiology and surgery*. Vol. 15, No. 6, pp. 909-20, 2020.
- [18] Srinivas B, Sasibhushana Rao G. Segmentation of Multi-Modal MRI Brain Tumor Sub-Regions Using Deep Learning. Journal of Electrical Engineering & Technology. Vol. 15, pp. 1899-909, 2020.
- [19] Li W, Wang G, Fidon L, Ourselin S, Cardoso MJ, Vercauteren T, editors. On the

## سپاسگزاری

از حمایت مادی و معنوی معاونت محترم پژوهش و فناوری دانشگاه اصفهان در قالب طرح مصوب با کد ۹۹۱۲۰۱۱ در اجرای این تحقیق سپاسگزاری می شود.

## مراجع

- [1] Zhou C, Chen S, Ding C, Tao D, editors. Learning contextual and attentive information for brain tumor segmentation. *International MICCAI Brainlesion Workshop*, 2018, Springer.
- [2] Weninger L, Rippel O, Koppers S, Merhof D, editors. Segmentation of brain tumors and patient survival prediction: methods for the BraTS 2018 challenge. *International MICCAI Brainlesion Workshop*; 2018: Springer.
- [3] Havaei M, Davy A, Warde-Farley D, Biard A, Courville A, Bengio Y, et al. Brain tumor segmentation with deep neural networks. *Medical image analysis*. Vol. 35, pp.18-31, 2017.
- [4] Karimi D, Salcudean SE. Reducing the hausdorff distance in medical image segmentation with convolutional neural networks. *IEEE Transactions on medical imaging*. Vol. 39, No. 2, pp. 499-513, 2019.
- [5] Arabi H, Dowling JA, Burgos N, Han X, Greer PB, Koutsouvelis N, et al. Comparative study of algorithms for synthetic CT generation from MRI: Consequences for MRI-guided radiation planning in the pelvic region. *Medical physics*. Vol. 45, No.11, pp. 5218-33, 2018.
- [6] Arabi H, Zeng G, Zheng G, Zaidi H. Novel adversarial semantic structure deep learning for MRI-guided attenuation correction in brain PET/MRI. European journal of nuclear medicine and molecular imaging. Vol. 46, No. 13, pp. 2746-59, 2019.
- [7] Bahrami A, Karimian A, Fatemizadeh E, Arabi H, Zaidi H. A new deep convolutional neural network design with efficient learning capability: Application to CT image synthesis from MRI. *Medical physics*. 2020.
- [8] Arabi H, Zaidi H. Whole-body bone segmentation from MRI for PET/MRI attenuation correction using shape-based averaging. *Medical physics*. Vol. 43, No. 11, p. 5848, 2016.
- [9] Isensee F, Kickingereder P, Wick W, Bendszus M, Maier-Hein KH, editors. Brain

- *Intelligence in Electrical Engineering*, Vol. 11, No. 3, pp. 1-12, 2020
- [24] Seyyedsalehi Z, Seyyedsalehi A. Bidirectional Layer-by-layer Pre-training Method. *Computational Intelligence in Electrical Engineering*, Vol. 6, No. 2, pp. 1-10, 2015
- [25] Gibson E, Li W, Sudre C, Fidon L, Shakir DI, Wang G, et al. NiftyNet: a deep-learning platform for medical imaging. *Computer methods and programs in biomedicine*. Vol. 158, pp. 113-22, 2018.
- [26] Arabi H, Zaidi H. Deep learning-based metal artefact reduction in PET/CT imaging. *Eur Radiol.* 2021, In press.
- [27] Taha AA, Hanbury A. Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool. *BMC medical imaging*. Vol. 15, No. 1, p. 29, 2015.
- [28] Karimi D, Dou H, Warfield SK, Gholipour A. Deep learning with noisy labels: Exploring techniques and remedies in medical image analysis. *Medical Image Analysis*. Vol. 62, p. 101759, 2020.

- compactness, efficiency, and representation of 3D convolutional networks: brain parcellation as a pretext task. *International conference on information processing in medical imaging*; 2017: Springer.
- [20] Arabi H, Zaidi H. Deep learning-guided estimation of attenuation correction factors from time-of-flight PET emission data. *Med Image Anal.* Vol. 64, p. 101718, 2020.
- [21] Arabi H, Bortolin K, Ginovart N, Garibotto V, Zaidi H. Deep learning-guided joint attenuation and scatter correction in multitracer neuroimaging studies. *Human brain mapping*, Vol. 41, No. 13, pp 79-3667, 2020.
- [22] Rastiboroujeni R, Teshnehlab M, Jafari R. A CAD System for Identification and Classification of Breast Cancer Tumors in DCE-MR Images Based on Hierarchical Convolutional Neural Networks. Computational Intelligence in Electrical Engineering, Vol. 6, No. 1, pp. 1-14, 2015
- [23] Sheykhivand S, Meshgini S, Mousavi Z. Automatic Detection of Various Epileptic Seizures from EEG Signal Using Deep Learning Networks. *Computational*

<sup>&</sup>lt;sup>1</sup> High Grade Gliomas

<sup>&</sup>lt;sup>2</sup> Low Grade Gliomas

<sup>&</sup>lt;sup>3</sup> Magnetic Resonance Imaging

<sup>&</sup>lt;sup>4</sup> Cascade architecture

<sup>&</sup>lt;sup>5</sup> fully connected multi-scale CNN

<sup>&</sup>lt;sup>6</sup> T1-weighted

<sup>&</sup>lt;sup>7</sup> T1-weighted imaging with gadolinium enhancing contrast

<sup>&</sup>lt;sup>8</sup> T2-weighted

<sup>&</sup>lt;sup>9</sup> TensorFlow-based open-source convolutional neural networks

<sup>&</sup>lt;sup>10</sup> Convolution kernel

<sup>11</sup> Dilated convolutional kernel

<sup>&</sup>lt;sup>12</sup> Residual connection

<sup>&</sup>lt;sup>13</sup> Batch normalization

<sup>14</sup> ReLU

<sup>15</sup> Residual blocks

<sup>&</sup>lt;sup>16</sup> Adaptive Moment Estimation

<sup>&</sup>lt;sup>17</sup> Sensitivity

<sup>&</sup>lt;sup>18</sup> Precision

<sup>&</sup>lt;sup>19</sup> Dice similarity coefficient

<sup>&</sup>lt;sup>20</sup> Jaccard index

<sup>&</sup>lt;sup>21</sup> Hausdorff distance